



Algoritmos genéticos e LLM no diagnóstico de Diabetes em mulheres

Estudo sobre a melhoria dos hiperparâmetro do modelo de machine learning

Repositório Github: <https://github.com/lucasbreder/diabetes-app>

Vídeo Explicativo: <https://youtu.be/aO5DEgT-yHM>

Link-DataSet: <https://www.kaggle.com/datasets/mathchi/diabetes-data-set/data>

Integrante

Daniel Sousa Melo

Ivan Schneider Lopes

Leonardo Matos Lourenço

Leandro Ximenes Bezerra de Medeiros

1. Introdução

O estudo utilizado como base neste novo trabalho buscou criar um modelo de machine learning para apoio ao diagnóstico de diabetes em mulheres. Neste aprimoramento, o objetivo é utilizar algoritmos genéticos para otimizar os hiperparâmetros dos diversos modelos e, assim, aumentar a assertividade dos diagnósticos.

Além disso, foi integrada ao projeto uma LLM (Large Language Model) que fornece informações detalhadas e orientações sensíveis ao contexto, baseadas tanto no pré-diagnóstico do modelo quanto nos dados antropométricos fornecidos pela paciente

2. Decisões Estratégicas e Operadores Genéticos

A primeira etapa do projeto buscou levantar as melhores configurações para a construção do Algoritmo Genético (AG). Inicialmente, foram desenhados três cenários com focos diferentes: maior exploração, equilíbrio e maior refinamento (exploração). Tal abordagem foi selecionada para abranger o maior número de soluções possíveis e não direcionar o otimizador apenas para o modelo que já era vencedor no cenário baseline (sem otimizações).

Em seguida, foram estabelecidos três tamanhos de população associados a diferentes taxas de mutação. O cenário focado em **exploração** utilizou uma população menor combinada a uma alta taxa de mutação, garantindo saltos maiores no espaço de busca e impedindo que o algoritmo ficasse preso a mínimos locais. Já no cenário focado em **aproveitamento**, foi selecionada uma população maior com baixíssima mutação, permitindo consolidar e aprimorar as soluções subótimas já encontradas.

O próximo parâmetro analisado foram as taxas de cruzamento (crossover), escolhidas entre 0.8 e 0.9. Essas taxas altas foram definidas para garantir uma forte recombinação genética, aproveitando o máximo das características dos melhores pais selecionados. Para evitar que as melhores soluções fossem perdidas entre as gerações durante esse processo agressivo de cruzamento, aplicou-se também a técnica de Elitismo e preservou-se uma margem de 10% a 20% de clonagem direta.

Por fim, atuando como um contrabalanço às taxas de cruzamento, utilizou-se taxas de mutação proporcionais às estratégias de cada experimento: mutações maiores (30%) para garantir diversidade na exploração, e menores (5%) para não corromper os bons indivíduos na fase de aproveitamento.

3. Otimização com Algoritmos Genéticos

Configurações dos Experimentos

Experimento	Foco da Abordagem	Tamanho da População	Gerações	Taxa de Cruzamento	Taxa de Mutação	Torneio (k)	Elitismo
Exp 1	População Pequena / Mutação Alta (Maior exploração aleatória)	20	15	80% (0.80)	30% (0.30)	3	2
Exp 2	População Média / Mutação Moderada (Equilíbrio)	30	20	85% (0.85)	15% (0.15)	4	3
Exp 3	População Grande / Mutação Baixa (Maior refinamento local)	40	25	90% (0.90)	5% (0.05)	5	4

3.1. Desempenho dos Modelos Baseline (Sem Otimização)

Antes de aplicar o Algoritmo Genético, avaliamos o desempenho padrão dos modelos usando hiperparâmetros convencionais.

Modelo	Recall (Sensibilidade)	Especificidade	F1-Score	Equidade
KNeighborsClassifier	0.6481	0.7400	0.6087	0.8880

DecisionTreeClassifier	0.5926	0.7600	0.5818	0.8979
LogisticRegression	0.7407	0.7400	0.6667	0.7769
RandomForestClassifier	0.5370	0.8300	0.5800	0.8141


Observação: No cenário baseline, a *Logistic Regression* apresentou o melhor balanceamento geral, com o recall mais alto (0.7407) entre os modelos não otimizados.



3.2. Resultados da Otimização via Algoritmo Genético

O Algoritmo Genético foi configurado para rodar em 3 experimentos distintos para avaliar o impacto das configurações de população e taxas de mutação. A tabela abaixo apresenta a melhor configuração encontrada para cada modelo após a evolução.

Modelo	Melhor Experimento	Configuração do AG	Hiperparâmetros Otimizados Encontrados
KNeighbors	Exp2	População: 20 Mutação: 15%	n_neighbors: 12, weights: 'distance', metric: 'minkowski', p: 3
DecisionTree	Exp1	População: 20 Mutação: 30%	max_depth: 2, min_samples_split: 21, min_samples_leaf: 13, criterion: 'entropy', class_weight: 'balanced'
LogisticReg	Exp2	População: 30 Mutação: 15%	C: 1.30, max_iter: 942, solver: 'saga', class_weight: 'balanced'

RandomForest	Exp1	População: 20 Muta��o: 30%	n_estimators: 336, max_depth: 29, min_samples_split: 20, min_samples_leaf: 16, criterion: 'entropy', class_weight: 'balanced'
---------------------	------	-----------------------------------	--







3.3. Comparativo de Impacto: Baseline vs. Otimizado

Abaixo, apresentamos o impacto da otimização nas métricas, focando especialmente no ganho de Sensibilidade (Recall), que é a prioridade do problema de saúde feminina proposto.

Modelo	Recall Baseline	Recall Otimizado	Variação (Δ)	Especificidade Final	F1-Score Final	Equidade Final
KNeighbors	0.6481	0.6481	+0.0000	0.7900	0.6364	0.8317
DecisionTree	0.5926	0.8704	+0.2778	0.5600	0.6483	0.8563
LogisticReg	0.7407	0.7407	+0.0000	0.7400	0.6667	0.7769
RandomForest	0.5370	0.7407	+0.2037	0.7000	0.6452	0.7127





3.4. Análise de Equidade

Em modelos de Machine Learning aplicados à saúde, avaliar apenas a acurácia ou o recall global pode esconder falhas em subgrupos específicos. Para garantir que o modelo otimizado seja justo, incorporamos a métrica de **equidade**. Essa métrica foi calculada observando a variação da Sensibilidade (Recall) entre diferentes faixas etárias de pacientes. O objetivo do otimizador foi penalizar configurações de hiperparâmetros que beneficiassem uma idade em detrimento de outra. Isso reduz o viés algorítmico (bias) e garante um desempenho consistente e seguro para todas as mulheres, independentemente do seu grupo demográfico.


3.5. Conclusões do Experimento

O Algoritmo Genético foi eficaz de forma substancial nos modelos baseados em árvores. A *DecisionTreeClassifier* teve um salto massivo no Recall (+27,78%), atingindo a marca de **0.8704**, garantindo que pouquíssimos casos de diabetes passariam despercebidos. O *Random Forest* também teve um salto expressivo (+20,37%).

Apesar de ter atingido o melhor Recall (0.8704), a árvore de decisão perdeu bastante Especificidade, caindo para 0.5600, o que geraria muitos alarmes falsos em pacientes saudáveis.

Os hiperparâmetros da Regressão Logística Baseline já estavam em um "ótimo global" para essa base de dados, visto que o Algoritmo Genético não conseguiu encontrar uma variação que melhorasse substancialmente o fitness.

Analisando a métrica multiobjetivo, o modelo **RandomForestClassifier** apresenta a melhor relação risco/benefício para o negócio. Ele saltou de um péssimo Recall (0.53) para um ótimo Recall (0.74), mantendo uma taxa decente de Especificidade (0.70) e um F1-Score equilibrado.



4. Integração com LLM e Prompt Engineering

Para melhorar a interpretabilidade dos diagnósticos, integramos o modelo *Llama 3.2 1B* executado localmente via *Ollama*. A escolha por um modelo local garante a privacidade absoluta dos dados das pacientes.

As técnicas de Prompt Engineering foram desenhadas para atender ao contexto médico feminino. O prompt instrui a IA a adotar uma linguagem empática e sensível ao gênero, traduzindo os dados numéricos em orientações práticas que levam em consideração fatores de risco sociais, como histórico gestacional e impactos do estresse da dupla jornada.

Por fim, as saídas do modelo foram estruturadas para serem salvas automaticamente em um arquivo `.jsonl`, preparando a base de dados necessária para o fine-tuning da Fase 3.

4.1. Engenharia de prompt

O prompt foi pensado para estabelecer uma comunicação simples, direta e concisa mas tendo a sensibilidade ao contexto médico. Também se reforçou o gênero das pacientes:

Você é um assistente médico especializado no diagnóstico de diabetes em mulheres.

Analise os dados clínicos abaixo e a predição do modelo de IA, e forneça uma interpretação técnica ao profissional de saúde especializado que irá interpretar o resultado. Seja empático e sensível ao gênero feminino.

*****Dados Clínicos do Paciente:*****

- Gravidezes: {dados_paciente.get("Pregnancies", "N/A")}
- Glicose: {dados_paciente.get("Glucose", "N/A")} mg/dL
- Pressão Sanguínea: {dados_paciente.get("BloodPressure", "N/A")} mm Hg
- Espessura da Pele: {dados_paciente.get("SkinThickness", "N/A")} mm
- Insulina: {dados_paciente.get("Insulin", "N/A")} mu U/ml
- IMC: {dados_paciente.get("BMI", "N/A")}
- Histórico Familiar (Pedigree): {dados_paciente.get("DiabetesPedigreeFunction", "N/A")}
- Idade: {dados_paciente.get("Age", "N/A")} anos

*****Resultado do Modelo de IA:***** {resultado_texto}

*****Certeza do Modelo:***** {certeza}

Por favor, forneça:

- 1. Uma explicação do resultado em linguagem simples*
- 2. Quais valores clínicos chamam mais atenção (acima ou abaixo dos limites normais)*
- 3. Recomendações gerais de saúde levando em consideração o contexto da paciente (quantidade de filhos e IMC por exemplo)*
- 4. De insights para o profissional de saúde de como abordar o resultado*
- 5. Lembre ao profissional de saúde para observar o uso correto de pronome de tratamento e da sensibilidade ao contexto social da paciente.*

Responda em português brasileiro. Seja conciso (máximo 15 linhas).

4.2. Exemplo de resposta gerada

Explicação do Resultado:

O modelo de IA analisa dados clínicos para determinar a presença de diabetes. Em sua maioria, o resultado é positivo (diabetes). Isso pode ser atribuído à gravidade dos sintomas ou ao nível de insulina produzida pelo fígado (hipoglicemia). No entanto, não há informações suficientes para uma conclusão precisa.

Valores Clínicos Notáveis:

- Gravidezes: 4.0 - Sabe-se que o risco aumenta com cada gravidez.
- Pressão Sanguínea: 60.0 mm Hg - Considerada hipertensão.
- Espessura da Pele: 22.0 mm - Sólido indício de diabetes.
- Histórico Familiar (Pedigree): 1.0 - Não há familiares com diabetes pré-metabolito ou tipo 2.
- Idade: 45.0 anos - Prevenção e gestação antecipadas podem ajudar a reduzir o risco de desenvolver diabetes.

Recomendações Gerais de Saúde:

- Monitoramento rigoroso da pressão sanguínea e do nível de glicose durante a gravidez.
- Considerar a gestação antecipada com cuidado e monitoramento contínuos.
- Aumentar o peso para reduzir a hipertensão, conforme sugerido.

Insights para o Profissional:

- Fique atento às características individuais da paciente e considere fatores como histórico familiar e nível de atividade física durante a gravidez.
- Encoraje a prevenção pronta, desde a escolha do casamento até as decisões sobre a gestação.
- Esteja preparado para abordar questões relacionadas à saúde mental e emocional da paciente.

Lembre-se:

- A avaliação completa de cada paciente deve ser feita com base em todos os dados disponíveis, incluindo histórico familiar, diagnóstico prévio e contexto social.
- É crucial considerar a sensibilidade social e cultural da paciente ao abordar questões relacionadas à saúde.

5. Considerações Éticas e Desafios

A utilização de tecnologia para assuntos relacionados à saúde implica em cuidados principalmente relacionados à privacidade e impacto social, além dos desafios técnicos e de infraestrutura.

No quesito privacidade o uso de IA generativa na saúde traz riscos inerentes ao vazamento de dados sensíveis de pacientes. Para mitigar esse problema foi selecionada uma solução de uso local da IA desta forma limitamos o compartilhamento de informações em servidores de terceiros.

Outro ponto de atenção são os vieses, como demonstrado no estudo anterior, o dataset é de uma base de dados da década de 1990 e o tamanho da população aliado ao desbalanceamento dos dados não contribui para uma generalização no contexto atual, para minimizar esse desafio foi integrado a métrica de Equidade.

No contexto social, um desafio é o uso de pronomes considerando o gênero das pacientes, dado que temas sensíveis como gravidez e a forma com a IA generativa vai utilizar os tratamentos são desafios importantes. Dada a limitação de recursos computacionais do experimento não foi possível usar modelos locais mais robustos, assim a forma de mitigar esse problema é o aprimoramento constante do prompt baseado nas interações já realizadas e o investimento em recursos computacionais mais robustos.

Por fim, o principal desafio enfrentado foi o alto custo computacional. A avaliação multiobjetivo no Algoritmo Genético exige o treinamento e validação cruzada dos modelos dezenas de vezes a cada geração. Para viabilizar o treinamento o número de gerações foi reduzido, porém em outros cenários o paralelismo dos processos pode ser considerado como alternativa.

6. Conclusão geral

O experimento usado no presente estudo se mostrou altamente eficaz e as premissas bioinspiradas dos algoritmos genéticos foram fundamentais para a otimização do modelo em um cenário exploratório de hiperparâmetros.

Nota-se também que a premissa do algoritmo tem forte vínculo ao uso de recursos computacionais dado o tempo de execução do script, sendo assim uma possível futura otimização e o uso do paralelismo para redução do tempo de treinamento, porém ainda assim a necessidade de recursos computacionais deve ser sempre levada em consideração.

Por fim, pode-se concluir que o AG se mostra uma ferramenta poderosa em diversos cenários e deve ser considerada com frequência como uma alternativa para aprimoramento dos hiperparâmetros dos modelos de machine learning.