

Aplicação de Aprendizado de Máquina na Classificação de Câncer de Mama Utilizando Regressão Logística

Tech Challenge - Fase 1 Pós Tech IA para Devs (FIAP + Alura)

Turma: Segurança Pública

Alunos:

- *Wilson Silva Cunha [rm370006]*
- *Daniel da Silva Neto [rm369995]*
- *Ismael de Freitas Pinho [rm370127]*
- *Francisco de Assis Soares de Souza [rm370009]*

Tema: Classificação de Câncer de Mama

1. Introdução

O câncer de mama é uma das doenças que mais afetam mulheres em todo o mundo, sendo responsável por um elevado número de diagnósticos anuais.

A identificação precoce da doença é um fator determinante para o sucesso do tratamento e para o aumento das chances de sobrevivência das pacientes.

Com o avanço da ciência de dados e da inteligência artificial, técnicas de aprendizado de máquina têm sido amplamente utilizadas na área da saúde, especialmente no apoio ao diagnóstico médico.

Esses métodos permitem a análise de grandes volumes de dados clínicos, auxiliando na identificação de padrões que podem não ser facilmente perceptíveis por métodos tradicionais.

Nesse contexto, este trabalho tem como objetivo aplicar um modelo de aprendizado supervisionado para a classificação de tumores de mama em benignos ou malignos, utilizando a base de dados Wisconsin Breast Cancer Dataset.

O modelo escolhido para este estudo foi a Regressão Logística, por sua simplicidade, eficiência e ampla utilização em problemas de classificação binária.

A proposta consiste na realização de uma análise exploratória dos dados, seguida do pré-processamento das variáveis e do treinamento do modelo, avaliando seu desempenho por meio de métricas estatísticas adequadas.

O uso de modelos computacionais não substitui a avaliação médica, mas pode contribuir na precisão dos diagnósticos e auxiliar na tomada de decisão clínica.

2. Análise Exploratória dos Dados

A base de dados utilizada neste estudo foi o Wisconsin Breast Cancer Dataset, amplamente empregado em pesquisas acadêmicas relacionadas à classificação de tumores de mama.

O conjunto de dados é composto por 569 registros, representando exames clínicos, e 32 variáveis, incluindo a variável alvo.

Durante a etapa inicial de exploração, foi realizada a verificação da estrutura dos dados, dos tipos das variáveis e da existência de valores ausentes.

Observou-se que o conjunto de dados não apresenta valores nulos, indicando boa qualidade e consistência das informações disponíveis, o que dispensa a aplicação de técnicas de imputação.

As variáveis presentes no conjunto de dados são majoritariamente numéricas e correspondem a características extraídas de imagens digitalizadas de biópsias mamárias, como medidas de raio, textura, perímetro, área e concavidade dos tumores.

A variável alvo, denominada *diagnosis*, indica se o tumor é classificado como benigno ou maligno.

A análise da distribuição da variável alvo evidenciou um leve desbalanceamento entre as classes, com maior quantidade de casos benignos em relação aos malignos.

Esse comportamento é comum em bases de dados médicas reais e deve ser considerado nas etapas seguintes de modelagem e avaliação do desempenho do modelo.

3. Pré-processamento dos Dados

Após a análise exploratória, foi realizada a etapa de pré-processamento dos dados, com o objetivo de preparar o conjunto de informações para o treinamento do modelo de aprendizado de máquina.

Inicialmente, a variável alvo *diagnosis* foi transformada em valores numéricos, atribuindo-se o valor 0 para tumores benignos e 1 para tumores malignos, possibilitando sua utilização pelos algoritmos de classificação.

Em seguida, a coluna id foi removida do conjunto de dados, uma vez que se trata apenas de um identificador e não possui relevância para a predição do diagnóstico.

As demais variáveis numéricas foram mantidas como atributos de entrada do modelo. Dessa forma, as variáveis independentes foram organizadas na matriz X, enquanto a variável alvo foi armazenada no vetor y.

Posteriormente, o conjunto de dados foi dividido em dois subconjuntos: dados de treino e dados de teste, utilizando a proporção de 70% para treino e 30% para teste.

Essa separação permite avaliar o desempenho do modelo em dados não utilizados durante o processo de aprendizado.

Por fim, foi aplicada a técnica de padronização dos dados por meio do *StandardScaler*, garantindo que todas as variáveis apresentassem média zero e desvio padrão igual a um.

Esse procedimento é especialmente importante para algoritmos como a Regressão Logística, pois contribui para uma melhor convergência e desempenho do modelo.

4. Modelo Utilizado

Para a etapa de modelagem, foi utilizado o algoritmo de Regressão Logística, um método amplamente empregado em problemas de classificação binária.

Esse modelo foi escolhido por sua simplicidade, eficiência computacional e facilidade de interpretação, características que o tornam adequado para aplicações na área da saúde.

A Regressão Logística permite estimar a probabilidade de um determinado exame ser classificado como benigno ou maligno com base nas características fornecidas.

O modelo foi treinado utilizando exclusivamente o conjunto de dados de treino, previamente padronizado, garantindo que o processo de aprendizado não fosse influenciado por informações do conjunto de testes.

Durante o treinamento, foi definido um número máximo de iterações suficiente para assegurar a convergência do algoritmo.

Após o treinamento, o modelo tornou-se capaz de realizar previsões sobre novos dados, possibilitando a avaliação de seu desempenho na etapa seguinte.

5. Avaliação dos Resultados

Após o treinamento do modelo de Regressão Logística, foi realizada a avaliação de seu desempenho utilizando o conjunto de dados de teste, que não participou do processo de aprendizado.

Essa etapa é fundamental para verificar a capacidade de generalização do modelo em dados inéditos.

A principal métrica utilizada para a avaliação foi a acurácia, que representa a proporção de previsões corretas realizadas pelo modelo.

O classificador apresentou uma acurácia aproximada de 98%, indicando excelente desempenho na tarefa de classificação dos tumores de mama.

Além da acurácia, foi analisada a matriz de confusão, que permite visualizar de forma detalhada os acertos e erros do modelo para cada classe.

Os resultados mostraram que a maior parte dos tumores benignos e malignos foi corretamente classificada, com um número reduzido de erros.

Também foi gerado o relatório de classificação, que apresenta métricas como precisão (precision), revocação (recall) e F1-score.

As métricas obtidas indicam um desempenho equilibrado entre as classes, evidenciando que o modelo é capaz de identificar corretamente tanto tumores benignos quanto malignos.

6. Disponibilização do Código

Com o objetivo de garantir transparência, reprodutibilidade e acesso ao código desenvolvido, todo o projeto foi disponibilizado em um repositório público no GitHub.

O repositório contém o notebook com as etapas de análise exploratória, pré-processamento dos dados, treinamento do modelo e avaliação dos resultados.

O projeto foi desenvolvido em Python, utilizando bibliotecas consolidadas da área de ciência de dados.

O código pode ser acessado por meio do seguinte link:

Repósitorio GitHub: <https://github.com/DanielNeto1092/cancer-breast-logistic-ml>

Dataset: <https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data/data>

Vídeo Explicativo: www.pontoevirgula.dev/video-explicativo-tech-challenge-fase1

7. Conclusão

Neste trabalho, foi aplicada uma abordagem de aprendizado de máquina para a classificação de tumores de mama em benignos e malignos, utilizando a base de dados Wisconsin Breast Cancer Dataset.

A partir da análise exploratória, foi possível compreender a estrutura dos dados e verificar sua qualidade, possibilitando a aplicação das etapas seguintes de pré-processamento e modelagem.

O modelo de Regressão Logística apresentou excelente desempenho, alcançando uma acurácia aproximada de 98% no conjunto de teste, além de métricas equilibradas entre as classes analisadas.

Esses resultados indicam que o modelo foi capaz de identificar padrões relevantes nos dados e realizar previsões consistentes.

Os resultados obtidos demonstram o potencial do uso de técnicas de aprendizado de máquina como ferramentas de apoio ao diagnóstico médico.

Ressalta-se, entretanto, que tais modelos não substituem a avaliação clínica realizada por profissionais da saúde, devendo ser utilizados como suporte à tomada de decisão.

8. Considerações Finais e Trabalhos Futuros

Como trabalhos futuros, é possível explorar a aplicação de outros algoritmos de aprendizado de máquina, como Árvores de Decisão, Random Forest e Support Vector Machines, comparando seus desempenhos com o modelo de Regressão Logística.

Além disso, técnicas de balanceamento de classes e validação cruzada podem ser empregadas para aprimorar ainda mais os resultados.

Outra possibilidade consiste na utilização de modelos mais complexos, como redes neurais, bem como a integração de dados adicionais, visando aumentar a robustez e a capacidade de generalização do modelo.

9. Referências

KAGGLE. Breast Cancer Wisconsin Diagnostic Dataset. Disponível em:
<https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data/data>

KARANAM, S. Exploratory Data Analysis — Breast Cancer Wisconsin (Diagnostic) Dataset. Disponível em:
<https://medium.com/@shashmikaranam/exploratory-data-analysis-breast-cancer-wisconsin-diagnostic-dataset-6a3be9525cd>