

Algoritmos Geneticos no Diagnostico de Cancer de Mama em Mulheres

1. Resumo

Este relatorio apresenta a execucao do estudo de otimizacao de hiperparametros com Algoritmos Geneticos aplicada ao dataset Breast Cancer Wisconsin Diagnostic. O objetivo foi comparar modelos baseline e modelos otimizados, com prioridade para recall, por se tratar de um problema de apoio ao diagnostico medico, em que falsos negativos sao mais criticos.

O estudo avaliou quatro familias de modelos:

- `KNeighborsClassifier`
- `DecisionTreeClassifier`
- `LogisticRegression`
- `RandomForestClassifier`

Para cada familia, foram executados tres experimentos de Algoritmo Genetico, com selecao por torneio, crossover, mutacao, elitismo e registro por geracao.

2. Objetivo

O estudo foi estruturado para responder quatro perguntas:

- qual o desempenho baseline de cada modelo no conjunto de teste;
- se o Algoritmo Genetico melhora o recall de cada familia;
- quais sao os trade-offs entre recall, especificidade e F1-score;
- qual modelo apresenta o melhor equilibrio para recomendacao de uso clinico.

3. Dataset e Preparacao

O dataset utilizado foi o Breast Cancer Wisconsin Diagnostic, disponibilizado no `scikit-learn`.

- total de amostras: 569
- treino: 455
- teste: 114
- classe positiva: maligno

Etapas de preparacao:

- normalizacao com `StandardScaler`;

- split estratificado 80/20;
- avaliacao final no conjunto de teste;
- conjunto de validacao interno para a funcao de fitness do AG.

4. Modelos Baseline

Os modelos baseline foram treinados com configuracoes padrao e avaliados no conjunto de teste.

Modelo	Recall	Especificidade	F1-score	Acuracia
KNeighborsClassifier	90,48%	98,61%	93,83%	95,61%
DecisionTreeClassifier	90,48%	94,44%	90,48%	92,98%
LogisticRegression	95,24%	98,61%	96,39%	97,37%
RandomForestClassifier	92,86%	100,00%	96,30%	97,37%

Leitura inicial:

- LogisticRegression teve o maior recall entre os baselines;
- RandomForestClassifier teve especificidade perfeita no teste;
- KNeighborsClassifier apresentou baseline forte, mas abaixo de LogisticRegression em recall;
- DecisionTreeClassifier foi o baseline menos equilibrado.

5. Algoritmo Genetico

5.1 Funcao de fitness

A funcao de fitness foi definida com prioridade explicita para recall:

$$\text{fitness} = (0.6 \text{ recall}) + (0.3 \text{ f1_score}) + (0.1 * \text{especificidade})$$

Essa escolha busca manter foco clinico na reducao de falsos negativos, sem ignorar o equilibrio geral do classificador.

5.2 Operadores utilizados

- inicializacao aleatoria da populacao;
- selecao por torneio;
- crossover uniforme;
- mutacao aleatoria por gene;
- elitismo;
- registro do melhor fitness e do fitness medio por geracao.

5.3 Configuracoes executadas

Foram executados tres experimentos para cada modelo:

1. Experimento 1 - Exploracao

- populacao: 20
- geracoes: 15
- crossover: 0.80
- mutacao: 0.30
- torneio: 3
- elitismo: 2

2. Experimento 2 - Equilibrio

- populacao: 30
- geracoes: 20
- crossover: 0.85
- mutacao: 0.15
- torneio: 4
- elitismo: 3

3. Experimento 3 - Refinamento

- populacao: 40
- geracoes: 25
- crossover: 0.90
- mutacao: 0.05
- torneio: 5
- elitismo: 4

6. Resultados da Otimizacao

Os resultados abaixo foram extraidos da execucao real registrada em results.json.

Modelo	Recall Baseline	Recall Otimizado	Delta Recall	Especificidade Final	F1-score Final
KNeighborsClassifier	90,48%	92,86%	2,38 p.p.	95,83%	92,86%
DecisionTreeClassifier	90,48%	88,10%	-2,38 p.p.	98,61%	92,50%
LogisticRegression	95,24%	95,24%	0,00 p.p.	98,61%	96,39%
RandomForestClassifier	92,86%	88,10%	-4,76 p.p.	98,61%	92,50%

6.1 Melhor experimento por modelo

- `KNeighborsClassifier`: `experimento_1_exploracao`
- `DecisionTreeClassifier`: `experimento_2_equilibrio`
- `LogisticRegression`: `experimento_1_exploracao`
- `RandomForestClassifier`: `experimento_1_exploracao`

6.2 Hiperparametros otimizados encontrados

`KNeighborsClassifier`

- `n_neighbors = 2`
- `weights = distance`
- `p = 1`

`DecisionTreeClassifier`

- `max_depth = 9`
- `min_samples_split = 6`
- `min_samples_leaf = 1`
- `criterion = entropy`

`LogisticRegression`

- `C = 7.5`
- `max_iter = 600`
- `solver = liblinear`

`RandomForestClassifier`

- `n_estimators = 400`
- `max_depth = 30`
- `min_samples_split = 42`
- `min_samples_leaf = 3`

7. Analise Automatica dos Resultados

Leitura consolidada da execucao:

- o maior ganho de recall foi obtido por `KNeighborsClassifier`, com aumento de 2,38 pontos percentuais;
- `DecisionTreeClassifier` e `RandomForestClassifier` melhoraram alguns aspectos de equilibrio, mas perderam recall;

- LogisticRegression nao ganhou recall adicional, mas manteve o melhor equilibrio geral entre recall, especificidade e F1-score;
- a recomendacao automatica para uso clinico permaneceu em LogisticRegression.

Em termos praticos:

- KNeighborsClassifier foi o modelo com maior ganho de sensibilidade;
- LogisticRegression foi o modelo mais estavel;
- RandomForestClassifier nao sustentou no teste a vantagem observada na validacao do AG;
- DecisionTreeClassifier trocou recall por especificidade.

8. Interpretacao Tecnica

O estudo mostrou que otimizar por AG nem sempre significa melhorar o recall final em todas as familias. O comportamento foi diferente entre os modelos:


- em KNeighborsClassifier, o AG encontrou uma configuracao simples e eficaz, com ganho real de recall;
- em LogisticRegression, o baseline ja era muito forte e o AG apenas confirmou uma regioa otima, sem ganho de teste;
- em DecisionTreeClassifier e RandomForestClassifier, a otimizacao favoreceu solucoes mais conservadoras, com queda de recall e ganho de especificidade.

Isso reforca um ponto importante: em problemas clinicos, a escolha do melhor modelo nao pode depender apenas do fitness em validacao. O comportamento no conjunto de teste precisa ser analisado junto com os trade-offs.

9. Graficos e Evidencias Visuais


Arquivos gerados nesta execucao:

- Comparacao baseline vs otimizado




- Convergencia KNN - experimento 1

KNeighborsClassifier - experimento_1_exploracao




- Convergencia Decision Tree - experimento 2


DecisionTreeClassifier - experimento_2_equilibrio



- Convergencia Logistic Regression - experimento 1



- Convergencia Random Forest - experimento 1



Esses graficos mostram:

- melhor fitness por geracao;
- fitness medio por geracao;
- diversidade da populacao;
- individuos unicos por geracao;

- evolucao dos parametros do melhor individuo.

10. Interface, API e Operacao

O projeto tambem entrega componentes opcionais relevantes:

- interface em Streamlit para carregar dataset, executar baseline e AG, comparar metricas e consultar historico da LLM;
- API separada em FastAPI;
- logging em arquivo;
- persistencia de artefatos em JSON, JSONL e imagens;
- Docker e docker - compose;
- estrutura inicial em Terraform;
- documentacao de nuvem e escalabilidade.

11. Consideracoes Eticas

- o sistema e de apoio, nao de decisao autonoma;
- o foco em recall reduz falso negativo, mas pode elevar falso positivo;
- o dataset e academico e nao substitui validacao clinica real;
- a camada de LLM inclui aviso explicito de que a resposta nao substitui avaliacao medica;
- nao ha credenciais expostas no repositorio.

12. Conclusao

Com base nos resultados reais desta execucao:

- o AG trouxe ganho de recall apenas para `KNeighborsClassifier`;
- `LogisticRegression` permaneceu como melhor opcao geral;
- `DecisionTreeClassifier` e `RandomForestClassifier` nao sustentaram ganho de sensibilidade no teste;
- para uso clinico com o criterio adotado neste estudo, a recomendacao final e `LogisticRegression`.

O estudo cumpriu o objetivo de comparar baseline vs otimizado, registrar os melhores hiperparametros, gerar graficos de convergencia e produzir uma analise automatica coerente com as metricas observadas.